Robótica

Proyecto final: Pix2Pix

25 de mayo, 2020

Alejandro W. Tollola Martinez
Kalid Gabriel Gómez Aceves

1. Objetivo

Con base a un set de imágenes de 102 flores de especies distintas que suelen ser comunes en Reino Unido, entrenar a una red neuronal basada en redes condicionales adversariales con la arquitectura conocida como Pix2Pix para tratar de recuperar la imagen original a partir de una modificación de la misma con diversos filtros.

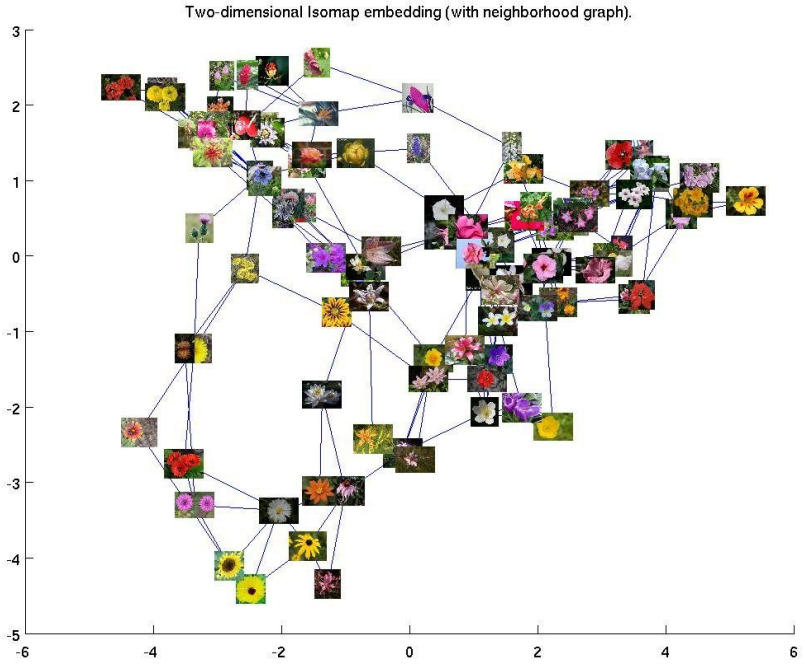

Para ello seguimos el tutorial de Dot CSV del link

2. Código

Originalmente tratamos de adaptar este código para usarlo en una máquina local, desafortunadamente aunque habilitamos el uso de Tensorflow para usar la tarjeta gráfica, el kernel de widows dejó de funcionar después de las 500 iteraciones en dos computadoras distintas llegando a corromper el arranque de una.

Debido a que la única distribución de linux con la que contábamos instalada en ese momento no era compatible con CUDA, decidimos usar el Notebook de google.

Al principio, declaramos la ubicación de las imágenes de entrada (Las borrosas) y las de salida, estas imágenes están en distintas carpetas y la imagen correspondiente tiene el mismo nombre de la imagen de entrada, después declaramos el porcentaje de imágenes que usará para entrenar (80%) y las que se usarán para poner a prueba el entrenamiento (20%).

```
import tensorflow as tf
import matplotlib.pyplot as plt
import numpy as np
from os import listdir

PATH = r"C:\Users\kalid\1Python\Robotica_2020-master\Python\pix2pix\flowersData"
#Datos de entrada
INPATH = PATH + r'\inputFlowers'
#Datos de salida
OUTPATH = PATH + r'\targetFlowers'
#Checkpoints
CKPATH = PATH + r'\checkpoints'

imgurls = listdir(INPATH)

# Cantidad de imágenes
n = 100
train_n = round(n * 0.80)

#lista randomizado
randurls = np.copy(imgurls)

np.random.seed(23) #solo para tutorial
np.random.shuffle(randurls)

#Partición train/test
tr_urls = randurls[:train_n]
ts_urls = randurls[train_n:n]
```

Después declaramos el tamaño de las imágenes junto con funciones que nos facilitarán multiplcar o hacer más grande la diversidad del banco de imágenes, tal como random_jitter, que recortará la imagen y aleatoriamente girará la imagen para que la red aprenda con un poco más de aleatoriedad.

Tenemos también una función que normalizará el valor R,G y B dentro de un valor de -1 a 1 en vez de 0 a 255.

```
IMG_WIDTH = 256
IMG_HEIGHT = 256

#reescalar imágenes
def resize(inimg, tgimg, height, width):
    inimg = tf.image.resize(inimg, [height, width])
    tgimg = tf.image.resize(tgimg, [height, width])

    return inimg,tgimg

#Normalizar el rango [-1, 1] la imagen
def normalize(inimg, tgimg):
    inimg = (inimg/127.5) - 1
    tgimg = (tgimg/127.5) - 1

    return inimg,tgimg

# Aumentación de datos : Random Crop + Flip
#Crear más fotos virtualmente, desplazando aleatorio y rotando horizontalmente
@tf.function() #compilarla fuera de eager mode de tensorflow, grafo computacional
def random_jitter(inimg,tgimg):
    inimg,tgimg = resize(inimg,tgimg,286,286)

    stacked_image = tf.stack([inimg, tgimg], axis = 0) #apilando imagenes una sobre otra
    cropped_image = tf.image.random_crop(stacked_image, size=[2, IMG_HEIGHT, IMG_WIDTH, 3]) #2 iam

    inimg,tgimg = cropped_image[0], cropped_image[1]

    #random flip, (()) no numero escalar
    if tf.random.uniform(()) > 0.5:

        inimg = tf.image.flip_left_right(inimg)
        tgimg = tf.image.flip_left_right(tgimg)

    return inimg,tgimg
```

Después programamos la función que interpretará las imágenes, tanto si son para entrenar o probar.

```
def load_images(filename, augment=True):
    inimg = tf.cast(tf.image.decode_jpeg(tf.io.read_file(INPATH + '/' + filename)), tf.float32)[.
    tgimg = tf.cast(tf.image.decode_jpeg(tf.io.read_file(OUTPATH + '/' + filename)), tf.float32)[

    inimg, tgimg = resize(inimg, tgimg, IMG_HEIGHT, IMG_WIDTH)

    if augment:
        inimg, tgimg = random_jitter(inimg,tgimg)

    inimg, tgimg = normalize(inimg,tgimg)

    return inimg,tgimg

def load_train_image(filename):
    return load_images(filename, True)

def load_test_image(filename):
    return load_images(filename,False)
```

Después creamos los Dataset de cada uno en el formato de Tensorflow que nos facilita las cosas

```
train_dataset = tf.data.Dataset.from_tensor_slices(tr_urls) #generar dataset a partir de listado
train_dataset = train_dataset.map(load_train_image, num_parallel_calls=tf.data.experimental.AUTOT
train_dataset = train_dataset.batch(1)

test_dataset = tf.data.Dataset.from_tensor_slices(ts_urls) #generar dataset a partir de listado
test_dataset = test_dataset.map(load_test_image, num_parallel_calls=tf.data.experimental.AUTOTUNE
test_dataset = test_dataset.batch(1)
```

Después definimos el downsampling, que consta de una reducción de la imagen inicial a unas matrices más pequeñas para poder interpretar y tomar la información mas relevante, este proceso funciona mediante convoluciones.

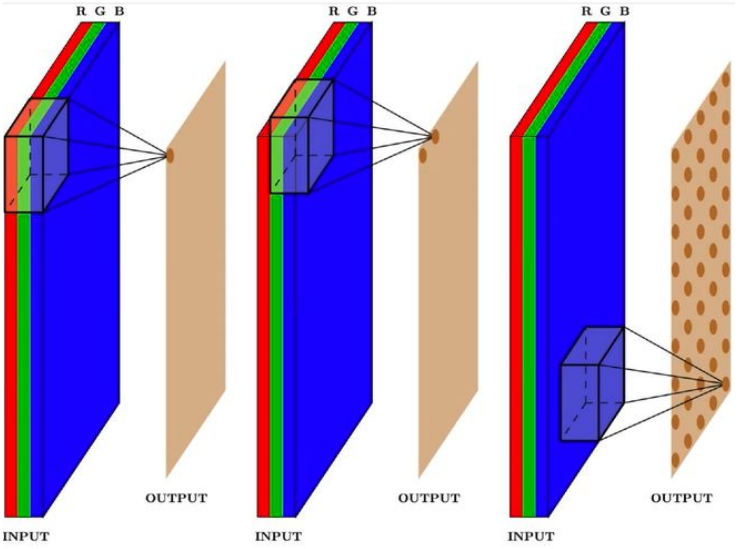

```python
from tensorflow.keras import *
from tensorflow.keras.layers import *

def downsample(filters, apply_batchnorm=True):

    result = Sequential() #secuencia de capaz

    initializer = tf.random_normal_initializer(0,0.02) #media y desviación estandar

    #Capa convolucional
    result.add(Conv2D(filters,
                      kernel_size=4,
                      strides=2,
                      padding="same",
                      kernel_initializer=initializer,
                      use_bias=not apply_batchnorm))

    if apply_batchnorm:
        #Capa de Batchnorm
        result.add(BatchNormalization())

    #Capa de activación
    result.add(LeakyReLU())

    return result

downsample(64)
```

Después programamos el upsampling, que es para al final obtener de nuevo una imagen del mismo tamaño a la de la entrada.

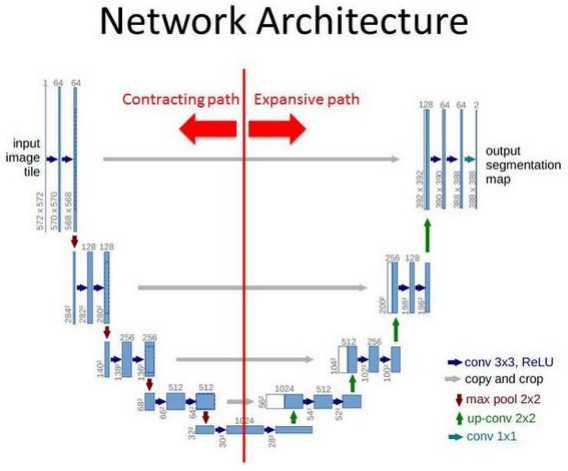

```python
def upsample(filters, apply_dropout=False):

    result = Sequential() #secuencia de capaz

    initializer = tf.random_normal_initializer(0,0.02) #media y desviación estandar

    #Capa convolucional
    result.add(Conv2DTranspose(filters,
                               kernel_size=4,
                               strides=2,
                               padding="same",
                               kernel_initializer=initializer,
                               use_bias=False))

    #Capa de Batchnorm
    result.add(BatchNormalization())

    if apply_dropout:
        #capa de dropout
        result.add(Dropout(0.5))

    #Capa de activación
    result.add(ReLU())

    return result
```

Finalmente utilizamos los valores empleados en la publicación de pix2pix para generar nuestra red neuronal.

```python
def Generator():
    inputs = tf.keras.layers.Input(shape=[None,None,3])

    down_stack = [
        downsample(64, apply_batchnorm=False),#(bs, 128, 128, 64)
        downsample(128),                      #(bs, 64,  64,  128)
        downsample(256),                      #(bs, 32,  32,  256)
        downsample(512),                      #(bs, 16,  16,  512)
        downsample(512),                      #(bs, 8,   8,   512)
        downsample(512),                      #(bs, 4,   4,   512)
        downsample(512),                      #(bs, 2,   2,   512)
        downsample(512),                      #(bs, 1,   1,   512)
    ]

    up_stack = [
        upsample(512, apply_dropout=True),  #(bs, 2,   2,   1024)
        upsample(512, apply_dropout=True),  #(bs, 4,   4,   1024)
        upsample(512, apply_dropout=True),  #(bs, 8,   8,   1024)
        upsample(512),                      #(bs, 16,  16,  1024)
        upsample(256),                      #(bs, 32,  32,  512)
        upsample(128),                      #(bs, 64,  64,  256)
        upsample(64),                       #(bs, 128, 128, 128)
    ]

    initializer = tf.random_normal_initializer(0,0.02) #media y desviación estandar

    last = Conv2DTranspose(filters = 3,
                           kernel_size=4,
                           strides=2,
                           padding="same",
                           kernel_initializer=initializer,
                           activation = "tanh")
```

```
    initializer = tf.random_normal_initializer(0,0.02) #media y desviación estandar

    last = Conv2DTranspose(filters = 3,
                           kernel_size=4,
                           strides=2,
                           padding="same",
                           kernel_initializer=initializer,
                           activation = "tanh")

    x = inputs #capas de convolución
    s = [] #skip connections

    concat = Concatenate()

    for down in down_stack:
        x = down(x)
        s.append(x)

    s = reversed(s[:-1])

    for up, sk in zip(up_stack, s):
        x = up(x)
        x = concat([x, sk])

    last = last(x)

    return Model(inputs=inputs, outputs=last)

generator = Generator()
```

Como podemos ver, se han creado conecciones para evitar perder información y enriquecer la información entre el dowsampling y el upsampling.

Después creamos el discriminador, que comparará a la imagen de salida contra la real para poder evaluar a la red neuronal.

```
def Discriminator():

    ini = Input(shape=[None,None,3], name="input_img")
    gen = Input(shape=[None,None,3], name="gener_img")

    con = concatenate([ini, gen])

    initializer = tf.random_normal_initializer(0,0.02) #media y desviación estandar

    down1 = downsample(64, apply_batchnorm=False)(con)
    down2 = downsample(128)(down1)
    down3 = downsample(256)(down2)
    down4 = downsample(1512)(down3)

    last = tf.keras.layers.Conv2D(filters=1,
                                  kernel_size=4,
                                   strides=1,
                                   kernel_initializer=initializer,
                                   padding="same")(down4)

    return tf.keras.Model(inputs=[ini, gen], outputs=last)

discriminator = Discriminator()
```

```
loss_object = tf.keras.losses.BinaryCrossentropy(from_logits=True)

def discriminator_loss(disc_real_output, disc_generated_output):
    # Diferencia entre los true por ser real y el detectado por el discriminador.
    real_loss = loss_object(tf.ones_like(disc_real_output), disc_real_output)

    #diferencia entre lso false por ser generado y el detectado por el discriminador
    generated_loss = loss_object(tf.zeros_like(disc_generated_output), disc_generated_output)

    total_disc_loss = real_loss + generated_loss

    return total_disc_loss
```

Después indicamos el proceso de balanceo y donde guardaremos los pesos de la red.

```
LAMBDA = 100

def generator_loss(disc_generated_output, gen_output, target):

    gan_loss = loss_object(tf.ones_like(disc_generated_output), disc_generated_output)

    #mean abolute error
    l1_loss = tf.reduce_mean(tf.abs(target - gen_output))

    total_gen_loss = gan_loss + (LAMBDA * l1_loss)

    return total_gen_loss
```

```
import os

generator_optimizer = tf.keras.optimizers.Adam(2e-4, beta_1=0.5)
discriminator_optimizer = tf.keras.optimizers.Adam(2e-4, beta_1=0.5)

checkpoint_prefix = os.path.join(CKPATH, "ckpt")
checkpoint = tf.train.Checkpoint(generator_optimizer=generator_optimizer,
                                 discriminator_optimizer=discriminator_optimizer,
                                 generator=generator,
                                 discriminator=discriminator)
```

Declaramos la función de creación de las imágenes a partir de nuestro modelo.

```
def generate_images(model, test_input, tar, save_filename=False, display_imgs=True):
    prediction = model(test_input, training=True)

    if save_filename:
        tf.keras.preprocessing.image.save_img(PATH + '/output/' + save_filename + '.jpg', predicti

    plt.figure(figsize=(10,10))

    display_list = [test_input[0], tar[0], prediction[0]]
    title = ['Input Image', 'Ground Truth', 'Predicted Image']

    if display_imgs:
        for i in range(3):
            plt.subplot(1,3, i+1)
            plt.title(title[i])
            # getting the pixel values between [0,1] to plot it
            plt.imshow(display_list[i]* 0.5+0.5)
            plt.axis('off')

    plt.show()
```

Declaramos nuestras funciones de entrenamiento

```
def  train_step(input_image, target):

    with tf.GradientTape() as gen_tape, tf.GradientTape() as discr_tape:

        output_image = generator(input_image, training = True)

        output_gen_discr = discriminator([output_image, input_image], training = True)

        output_trg_discr = discriminator([target, input_image], training = True)

        discr_loss = discriminator_loss(output_trg_discr, output_gen_discr)

        gen_loss = generator_loss(output_gen_discr, output_image, target)


        generator_grads = gen_tape.gradient(gen_loss, generator.trainable_variables)

        discriminators_grads = discr_tape.gradient(discr_loss, discriminator.trainable_variables)

        generator_optimizer.apply_gradients(zip(generator_grads, generator.trainable_variables))

        discriminator_optimizer.apply_gradients(zip(discriminators_grads, discriminator.trainable_
```

```
from IPython.display import clear_output

def train(dataset, epochs):
    for epoch in range(epochs):
        imgi=0
        for input_image, target in dataset:
            print('epoch ' + str(epoch) + ' - train: ' + str(imgi)+'/'+str(len(tr_urls)))
            imgi+=1
            train_step(input_image, target)
            clear_output(wait=True)

        for inp, tar in test_dataset.take(5):
            generate_images(generator, inp, tar, str(imgi) + '_' + str(epoch), display_imgs=True)
            imgi+=1

        #saving (checkpoint) the model every 20 seconds
        if(epoch + 1) % 50 == 0:
            checkpoint.save(file_prefix = checkpoint_prefix)
```

y finalmente ponemos a entrenar a la red neuronal

```
train(train_dataset, 100)
```

```
epoch 0 - train: 168/6400
```

3. Conclusiones